

# TAREA 2-MD

María Pallares Diez

2025-01-09

## Introducción

En esta tarea, realizaremos un Análisis de Componentes Principales (ACP) sobre dos bancos de datos: `datos` y `datos_b`. Los datos están contenidos en los archivos `datosp1.RData` y `datosp1_b.RData` respectivamente. Se calcularán las desviaciones típicas de las variables cuantitativas, se determinará el método adecuado para el ACP y se analizarán los resultados.

## Carga de datos

```
# Cargar los datos
load("datosp1.RData")
load("datosp1_b.RData")
```

### a. Desviaciones típicas y elección del método

#### Desviaciones típicas

```
# Filtrar solo columnas numéricas para evitar errores con factores
datos_numericos <- datos[sapply(datos, is.numeric)]
datos_b_numericos <- datos_b[sapply(datos_b, is.numeric)]

# Calcular desviaciones típicas para las variables cuantitativas de ambos bancos
sapply(datos_numericos, sd, na.rm = TRUE)
```

##	ID	Edad	Horas_estudio
##	29.0114920	0.8382979	4.7687462
##	Promedio_matematicas	Promedio_ciencias	Promedio_lectura
##	10.2286389	8.8425306	12.2432730
##	Asistencia	Horas_sueño	Nivel_estres
##	11.2869253	1.0321552	1.9232758
##	Uso_dispositivos	Condicion_fisica	Centro
##	1.8609792	47.7802480	2.4452799

```
sapply(datos_b_numericos, sd, na.rm = TRUE)
```

```
##           ID           Edad      Horas_estudio
##      29.0114920      0.8382979      5.9134713
## Promedio_matematicas Promedio_ciencias Promedio_lectura
##      10.2286389      11.2538682      14.0563689
##      Asistencia      Horas_sueño      Nivel_estres
##      14.6701543      4.4103372      1.9232758
##      Uso_dispositivos Condicion_fisica
##      1.8846981      86.9240511
```

## Justificación del método

A partir de las desviaciones típicas, si las variables tienen escalas muy diferentes, se usará la matriz de correlaciones para estandarizar las variables antes del análisis. De lo contrario, se usará la matriz de varianzas-covarianzas.

### Explicación:

Las desviaciones típicas muestran que las variables tienen escalas muy diferentes, especialmente para la variable `Condicion_fisica`. Por lo tanto, es apropiado usar la matriz de correlaciones para el ACP, ya que elimina el efecto de las diferencias de escala entre las variables.

## b. Análisis de Componentes Principales

### ACP para datos

```
# Realizar ACP
acp_datos <- prcomp(datos, scale. = TRUE)
summary(acp_datos)

## Importance of components:
##           PC1      PC2      PC3      PC4      PC5      PC6      PC7
## Standard deviation  1.4525 1.3021 1.1834 1.0979 1.05215 0.98765 0.94652
## Proportion of Variance 0.1758 0.1413 0.1167 0.1004 0.09225 0.08129 0.07466
## Cumulative Proportion 0.1758 0.3171 0.4338 0.5342 0.62650 0.70778 0.78244
##           PC8      PC9      PC10     PC11     PC12
## Standard deviation  0.85329 0.81256 0.77478 0.7275 0.30468
## Proportion of Variance 0.06068 0.05502 0.05002 0.0441 0.00774
## Cumulative Proportion 0.84312 0.89814 0.94816 0.9923 1.00000
```

**Pregunta 1: Porcentaje de varianza explicado** La varianza explicada por la primera componente es:

```
sum(acp_datos$sdev^2 / sum(acp_datos$sdev^2))
```

```
## [1] 1
```

### Explicación:

En `datos`, la primera componente principal (PC1) explica el **17.58%** de la varianza, mientras que la segunda (PC2) explica el **14.13%**, acumulando un **31.71%**. Esto sugiere que la información está distribuida entre varias componentes principales y no está concentrada en las primeras componentes.

## ACP para datos\_b

```
# Realizar ACP
acp_datos_b <- prcomp(datos_b_numericos, scale. = TRUE)
summary(acp_datos_b)
```

```
## Importance of components:
##              PC1      PC2      PC3      PC4      PC5      PC6      PC7
## Standard deviation  2.4324 1.3345 1.1036 0.95987 0.66354 0.51577 0.4350
## Proportion of Variance 0.5379 0.1619 0.1107 0.08376 0.04003 0.02418 0.0172
## Cumulative Proportion 0.5379 0.6998 0.8105 0.89428 0.93430 0.95849 0.9757
##              PC8      PC9      PC10     PC11
## Standard deviation  0.3181 0.29445 0.24833 0.13375
## Proportion of Variance 0.0092 0.00788 0.00561 0.00163
## Cumulative Proportion 0.9849 0.99277 0.99837 1.00000
```

```
cumsum(acp_datos_b$sdev^2) / sum(acp_datos_b$sdev^2)
```

### Pregunta 2: Número de componentes para el 90% de varianza

```
## [1] 0.5378821 0.6997907 0.8105167 0.8942766 0.9343028 0.9584867 0.9756877
## [8] 0.9848856 0.9927677 0.9983738 1.0000000
```

#### Explicación:

En `datos_b`, se necesitan solo **4 componentes** para explicar al menos el **90%** de la varianza, en contraste con las **9 componentes** necesarias en `datos`. Esto refleja una estructura más compacta en `datos_b`.

### Pregunta 3: Diferencias entre resultados Explicación:

En `datos`, las varianzas están más distribuidas entre las componentes principales, mientras que en `datos_b`, la primera componente (PC1) captura una proporción significativamente mayor de la varianza (**53.79%**). Esto puede deberse a una mayor redundancia o correlación entre las variables en `datos_b`.

## Interpretación de las componentes principales para datos\_b

```
# Cargar coeficientes de las primeras componentes
acp_datos_b$rotation[, 1:2]
```

```
##              PC1      PC2
## ID          0.395364841 -0.05210119
## Edad        0.005112111  0.20708039
## Horas_estudio 0.320546792  0.01956427
## Promedio_matematicas 0.393758942 -0.06443541
## Promedio_ciencias 0.386279064 -0.06794983
## Promedio_lectura 0.321949472 -0.04687938
## Asistencia    0.306390998 -0.04265555
```

## Horas_sueño	0.290299107	0.11345487
## Nivel_estres	0.057731577	0.68330863
## Uso_dispositivos	-0.379280034	0.10059616
## Condicion_fisica	0.087555041	0.67181237

#### Explicación:

- **PC1:** Está dominada por ID, Promedio\_matematicas, Promedio\_ciencias y Promedio\_lectura, lo que indica que representa una tendencia hacia un mejor rendimiento académico.
- **PC2:** Está influenciada por Nivel\_estres y Condicion\_fisica, sugiriendo un contraste entre aspectos psicológicos y físicos.

```
library(ggplot2)

# Crear un data frame con las primeras dos componentes
individuos <- data.frame(acp_datos_b$x[, 1:2])
colnames(individuos) <- c("Componente1", "Componente2")
individuos$Centro <- as.factor(datos_b$Centro) # Suponiendo que existe esta columna

# Gráfico
ggplot(individuos, aes(x = Componente1, y = Componente2, color = Centro)) +
  geom_point(size = 3) +
  theme_minimal() +
  labs(title = "Proyección de individuos en las dos primeras componentes principales",
       x = "Componente Principal 1",
       y = "Componente Principal 2") +
  theme(plot.title = element_text(hjust = 0.5, size = 16),
        axis.title = element_text(size = 14),
        legend.title = element_text(size = 12),
        legend.text = element_text(size = 10))
```

#### Pregunta 5: Gráfico de individuos



### Explicación:

El gráfico muestra que los individuos tienden a agruparse por centros, indicando diferencias características entre los centros. Sin embargo, hay solapamientos, lo que sugiere similitudes entre ciertos centros. La diferenciación en el gráfico refleja la variabilidad capturada por las dos primeras componentes principales.

### Conclusiones

Los resultados de este análisis muestran diferencias significativas entre los dos conjuntos de datos, **datos** y **datos\_b**. En **datos**, las varianzas están distribuidas de manera más uniforme entre las componentes principales, mientras que en **datos\_b** están concentradas en las primeras componentes, particularmente en la PC1, que explica el **53.79%** de la varianza.

En términos de interpretación:

- En **datos\_b**, la **PC1** refleja un rendimiento académico general, agrupando variables como Promedio\_matematicas, Promedio\_ciencias y Promedio\_lectura. La **PC2**, por otro lado, representa una interacción entre el Nivel\_estres y la Condicion\_fisica.
- Los gráficos muestran una clara diferenciación entre los individuos de distintos centros, aunque con cierto solapamiento, lo que indica que existen tanto diferencias significativas como similitudes entre ellos.

En conclusión, el ACP ha permitido identificar patrones relevantes en los datos, lo que facilita la interpretación y segmentación de los individuos en función de las componentes principales. La elección de la matriz de correlaciones ha sido clave para obtener estos resultados debido a las diferencias de escala entre las variables.