

# PRÁCTICA 2- Series Temporales (LITUANIA)

María Pallares Diez

2025-02-27

## Introducción

En este análisis, se estudia la evolución del **consumo eléctrico en Lituania** desde **enero de 2012 hasta diciembre de 2023**, utilizando datos de **Eurostat**. La serie temporal refleja la demanda energética del país, influenciada por **factores climáticos, económicos y geopolíticos**, y presenta **patrones estacionales** marcados por la variabilidad climática a lo largo del año.

Para modelar esta serie, se ha explorado el uso de **métodos de alisado exponencial (ETS)**, probando diferentes configuraciones y transformaciones (raíz cuadrada, inversa y ajuste por días laborables) con el objetivo de minimizar el error de predicción.

El estudio busca **seleccionar el modelo más adecuado**, evaluar su desempeño a través de métricas de error y validar su capacidad predictiva mediante una **comparación con un método ingenuo con estacionalidad**. Finalmente, se ha realizado una **predicción a tres años vista**, proporcionando una perspectiva sobre la evolución futura del consumo eléctrico en Lituania y la fiabilidad de las previsiones obtenidas.

```
library(forecast)
library(ggplot2)
library(tseries)
library(timeDate)
datos <- read.csv("ELE_Lituania.csv", header = TRUE)
electricidad <- ts(datos, start = c(2012, 1), frequency = 12)
ndiffs(electricidad, alpha = 0.05, test = "kpss")
```

```
## [1] 0
```

La prueba **KPSS** se ha aplicado a la serie de electricidad para determinar si es necesario diferenciarla para hacerla estacionaria. El resultado obtenido es **0**, lo que indica que la serie **ya es estacionaria y no requiere diferenciación**. Esto sugiere que se puede modelar directamente sin aplicar transformaciones adicionales para eliminar tendencias, lo que comprobaremos a continuación en la búsqueda del mejor modelo.

## Búsqueda del mejor modelo

Para seleccionar el mejor modelo de alisado exponencial para el **consumo eléctrico en Lituania**, se evaluaron **cuatro enfoques**:

1. **ETS(M,N,A)**: Aplicado directamente sobre la serie original.
2. **ETS(A,N,A) con raíz cuadrada**: Para reducir la varianza en series con heterocedasticidad.
3. **ETS(M,A,M) con transformación inversa**: Útil ante efectos de escala.



```

))
fechas <- seq(as.Date("2012-01-01"), by = "month", length.out = length(electricidad))
dias_laborables_lt <- sapply(fechas, function(x) sum(!weekdays(seq(x, length = 30, by = "day"))) %in% c(
mapeLab <- matrix(NA, s + 1, h)
for (i in 0:s) {
  train.set <- subset(electricidad / dias_laborables_lt, start = i + 1, end = i + k)
  test.set <- subset(electricidad, start = i + k + 1, end = i + k + h)
  fit <- ets(train.set, model = "ANA", damped = FALSE)
  fcast <- forecast(fit, h = h)
  predicted_original <- fcast$mean * dias_laborables_lt[i + k + 1] # Deshacer la transformación
  mapeLab[i + 1, ] <- 100 * abs(test.set - predicted_original) / test.set
}
errorLab <- apply(mapeLab, MARGIN = 2, FUN = median)
# Comparar errores de cada modelo
errores <- data.frame(
  Horizonte = 1:h,
  Normal = errorNormal,
  Raiz_Cuadrada = errorRaiz,
  Inversa = errorInv,
  Laborables = errorLab
)
print(errores)

```

##	Horizonte	Normal	Raiz_Cuadrada	Inversa	Laborables
## 1	1	2.701136	3.099808	3.124371	3.408927
## 2	2	3.834796	3.863402	4.716512	3.982686
## 3	3	3.904960	4.106227	7.055493	5.692220
## 4	4	4.643505	4.220252	7.903511	6.096004
## 5	5	8.190689	8.675442	8.553695	8.262513
## 6	6	8.842868	8.549035	9.532417	9.418650
## 7	7	10.578176	9.522932	9.540811	10.642168
## 8	8	10.492894	9.923654	11.026323	11.293280
## 9	9	10.773330	11.153195	12.176035	11.393935
## 10	10	11.356017	11.165228	12.707756	11.497979
## 11	11	11.667914	10.895326	13.150837	11.717753
## 12	12	12.121960	11.732180	12.965916	12.211458

La tabla presenta los errores **MAPE** para cada transformación aplicada a la serie de consumo eléctrico en Lituania. El modelo **ETS(M,N,A)** muestra los errores más bajos en los primeros meses y estabilidad en el largo plazo. Las transformaciones (Raíz Cuadrada, Inversa, Laborables) no mejoran la precisión y, en algunos casos, incrementan el error, mientras que el modelo inverso **ETS(M,A,M)** presenta los errores más altos, descartándolo.

Dado que la serie es **estacionaria**, según la prueba **KPSS**, las transformaciones no aportan mejoras significativas. Por ello, se selecciona **ETS(M,N,A)** como el mejor modelo sin necesidad de ajustes adicionales.

```

mejor_modelo <- ets(electricidad)
summary(mejor_modelo)

```

```

## ETS(M,N,A)
##
## Call:
## ets(y = electricidad)

```

```

##
## Smoothing parameters:
##   alpha = 0.5564
##   gamma = 1e-04
##
## Initial states:
##   l = 882.9695
##   s = 116.8095 44.3362 21.7039 -51.2182 -40.9389 -65.9988
##       -73.9594 -57.6515 -53.9676 35.8369 19.4219 105.6259
##
##   sigma: 0.0385
##
##      AIC      AICc      BIC
## 1751.192 1754.942 1795.740
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.04847888 33.12552 25.17995 -0.09890442 2.806865 0.5760404
##              ACF1
## Training set -0.008019885

```

El modelo seleccionado es **ETS(M,N,A)**, lo que indica que la serie presenta un **nivel multiplicativo**, **sin tendencia**, y **con estacionalidad aditiva**. Esto sugiere que la serie mantiene una estructura estacional constante, sin crecimiento ni decrecimiento en la tendencia.

Los **parámetros de suavizado** obtenidos son:

- $\alpha = 0.5564$ : Se asigna un peso moderado a las observaciones recientes, lo que indica que el modelo responde a los cambios en la serie sin ser demasiado reactivo.
- $\gamma = 1 \times 10^{-4}$ : La estacionalidad varía mínimamente en el tiempo, lo que indica estabilidad en los patrones estacionales.

El estado inicial muestra un **nivel base de 882.97**, con variaciones estacionales significativas.

El modelo presenta una **varianza del error (sigma) de 0.0385**, lo que sugiere que la dispersión en los residuos es baja y el modelo es estable.

En términos de criterios de información:

- **AIC** = 1751.19, **AICc** = 1754.94, **BIC** = 1795.74, lo que indica un **buen equilibrio entre ajuste y complejidad del modelo**.

## Indicadores de Calidad del Modelo

Para evaluar la precisión del modelo **ETS(M,N,A)** en la serie de **consumo eléctrico en Lituania**, se analizan las siguientes métricas de error:


- El **error medio (ME = -0.0484)** confirma que el modelo **no tiene un sesgo notable**, ya que no tiende a sobrestimar ni subestimar el consumo eléctrico.
- La **raíz del error cuadrático medio (RMSE = 33.12)** refleja la variabilidad de los errores, mostrando que las desviaciones entre las predicciones y los valores reales son moderadas.

- El **error absoluto medio** ( $MAE = 25.18$ ) indica que, en promedio, las predicciones difieren del valor real en aproximadamente 25 unidades de consumo eléctrico.
- El **error porcentual medio** ( $MPE = -0.0989\%$ ) señala que los errores no muestran una tendencia sistemática en términos relativos.
- El **error absoluto porcentual medio** ( $MAPE = 2.81\%$ ) evidencia que el modelo realiza **predicciones precisas**, con un margen de error bajo.
- El **error absoluto escalado medio** ( $MASE = 0.576$ ) sugiere que el modelo **supera a un método ingenuo con estacionalidad**, lo que refuerza su calidad predictiva.
- La **autocorrelación de los residuos en el primer retardo** ( $ACF1 = -0.0080$ ) indica que **los errores no siguen patrones sistemáticos**, lo que sugiere que la estructura de la serie ha sido bien capturada.

Estos resultados muestran que el modelo **ETS(M,N,A)** ofrece **predicciones precisas y errores bien distribuidos**, validando su adecuación para modelar la evolución del consumo eléctrico en Lituania.

### Predicción a 3 años vista

```
pronostico <- forecast(mejor_modelo, h = 36)
plot(pronostico, main = "Gráfico 1- Predicción a 3 años vista", ylab = "Consumo de Electricidad",
      xlab = "Año")
```



En la **Gráfica 1** se presenta la predicción del consumo eléctrico en Lituania para los próximos **3 años** utilizando el modelo **ETS(M,N,A)**, el cual ha demostrado ser el más adecuado para la serie. La serie original se muestra en **negro**, mientras que la predicción se representa en **azul**, con bandas de confianza en distintos tonos de **gris**.

Se observa que la predicción mantiene **un patrón estacional estable**, con aumentos y descensos regulares a lo largo del año, lo que indica que el modelo captura correctamente la **variabilidad cíclica del consumo**. La tendencia general del consumo parece **estable**, sin un crecimiento ni decrecimiento significativo, lo que sugiere que el comportamiento histórico se mantiene en las estimaciones futuras.

A medida que avanza el tiempo, las bandas de confianza se **ensanchan**, lo que refleja **mayor incertidumbre en las predicciones a largo plazo**. Esto es un comportamiento esperado en modelos de series temporales, ya que las pequeñas variaciones acumuladas generan mayor dispersión en las proyecciones futuras.

El modelo **ETS(M,N,A)** proporciona una estimación confiable en el corto y mediano plazo. Sin embargo, dada la creciente incertidumbre más allá del **primer año de predicción**, es recomendable actualizar y reevaluar el modelo periódicamente, especialmente considerando factores externos que puedan afectar el consumo energético en el país.

## Calidad de las previsiones con origen de previsión móvil

Para evaluar la precisión del modelo **ETS(M,N,A)**, se ha utilizado la metodología de **origen de previsión móvil**, donde se recalcula el error en distintos horizontes de predicción.

```
k <- 120
h <- 12
s <- length(electricidad) - k - h
mapeMovil <- matrix(NA, s + 1, h)
for (i in 0:s) {
  train.set <- subset(electricidad, start = i + 1, end = i + k)
  test.set <- subset(electricidad, start = i + k + 1, end = i + k + h)
  fit <- ets(train.set, model = "MNA", damped = FALSE)
  fcast <- forecast(fit, h = h)
  predicted_original <- fcast$mean
  mapeMovil[i + 1, ] <- 100 * abs(test.set - predicted_original)/test.set
}
errorMovil <- apply(mapeMovil, MARGIN = 2, FUN = median)
print(errorMovil)
```

```
## [1] 2.701136 3.834796 3.904960 4.643505 8.190689 8.842868 10.578176
## [8] 10.492894 10.773330 11.356017 11.667914 12.121960
```

El análisis de los errores MAPE obtenidos revela que **la precisión del modelo ETS(M,N,A) es alta en el corto plazo, pero se deteriora conforme aumenta el horizonte de predicción**.


- Se observa que **el error de predicción aumenta con el horizonte de previsión**, lo que es un comportamiento esperado en modelos de series temporales.
- En los **primeros 3 meses**, el **MAPE se mantiene por debajo del 5%**, indicando una alta precisión en predicciones a corto plazo.
- A partir del **quinto mes**, el error comienza a **incrementarse de forma más pronunciada**, superando el **10% después del séptimo mes**.
- En los últimos meses de previsión, el error **se estabiliza en torno al 12%**, lo que sugiere una disminución en la confiabilidad del modelo a largo plazo.

Estos resultados indican que el modelo **ETS(M,N,A)** ofrece **buenas predicciones en el corto plazo**, pero su precisión disminuye a medida que se extiende el horizonte de previsión, debido a la acumulación de incertidumbre en la tendencia y la estacionalidad.

## Valores extremos

```
# Generar las fechas reales de la serie temporal
fechas <- seq(as.Date("2012-01-01"), by = "month", length.out = length(electricidad))
# Obtención de los residuos
residuos <- residuals(mejor_modelo)
# Cálculo de la desviación estándar de los residuos
sd_residuos <- sd(residuos)
limite_superior <- 2.5 * sd_residuos
limite_inferior <- -2.5 * sd_residuos
autoplot(residuos, series = "Error", colour = "black", xlab = "Periodo", ylab = "Error",
  main = "Gráfica 2 - Residuos con límites de valores extremos") + geom_hline(yintercept = c(-2.5,
-2, 2, 2.5) * sd_residuos, colour = c("red", "blue", "blue", "red"), lty = 2) +
  scale_x_continuous(breaks = seq(2012, 2024, 2))
```

Gráfica 2 – Residuos con límites de valores extremos



```
valores_extremos <- fechas[abs(residuos) > limite_superior]
valores_extremos
```

```
## [1] "2012-01-01" "2021-12-01" "2023-11-01"
```

La **Gráfica 2** muestra los residuos del modelo **ETS(M,N,A)** con límites de  $\pm 2.5$  desviaciones estándar, en lugar del umbral de 3 que se había considerado previamente. Esta reducción ha permitido detectar **tres valores extremos** en la serie: **enero de 2012**, **diciembre de 2021** y **noviembre de 2023**.

### Valores Extremos Detectados

Se han identificado tres valores extremos en la serie. **Enero de 2012** coincide con una **fuerte ola de frío en Europa**, lo que incrementó la demanda de calefacción y provocó un aumento inusual en el consumo eléctrico.

**Diciembre de 2021** marca el inicio de la **crisis energética en Europa**, cuando la incertidumbre en el suministro de gas disparó los precios y generó fluctuaciones en la demanda. **Noviembre de 2023** podría estar relacionado con **ajustes en el mercado energético post-crisis**, reflejando cambios en la oferta y demanda.

Estos eventos externos han afectado el comportamiento del consumo eléctrico, generando anomalías en los residuos del modelo. Aunque el **ETS(M,N,A)** captura bien la estructura de la serie, la inclusión de **variables exógenas** podría mejorar su capacidad predictiva en contextos de alta volatilidad.

## Comparación del modelo ajustado por Alisado Exponencial con el método ingenuo con estacionalidad

Se ha comparado el modelo **ETS(M,N,A)** con el **método ingenuo con estacionalidad**, evaluando la calidad del ajuste mediante diversas métricas.

```
metodo_ingenuo <- snaive(electricidad, h = 36)
mase_alisado <- accuracy(mejor_modelo)[, "MASE"]
mase_ingenuo <- accuracy(metodo_ingenuo)[, "MASE"]
cat("MASE del modelo de alisado:", mase_alisado, "\n")
```

```
## MASE del modelo de alisado: 0.5760404
```

```
cat("MASE del método ingenuo:", mase_ingenuo, "\n")
```

```
## MASE del método ingenuo: 1
```

El modelo **ETS(M,N,A)** obtiene un **MASE de 0.576**, mientras que el método ingenuo tiene un **MASE de 1**. Esto indica que el modelo de alisado exponencial logra reducir el error en aproximadamente **42%** en comparación con la predicción basada en estacionalidad simple.

Por lo que, podemos concluir que el modelo **ETS(M,N,A)** es más preciso que el método ingenuo, mostrando un mejor ajuste a la serie y proporcionando predicciones más fiables.

## Conclusiones

El análisis del **consumo eléctrico en Lituania** ha permitido modelar su evolución con **alisado exponencial (ETS)**, determinando que el modelo **ETS(M,N,A)** es el más adecuado. Su **MAPE del 2.79%** indica una **buena precisión en la predicción**, y su **MASE de 0.57** confirma que supera al método ingenuo con estacionalidad.

La **predicción a tres años** muestra que el consumo eléctrico **mantendrá su patrón estacional**, aunque con **mayor incertidumbre a largo plazo**, reflejada en el ensanchamiento de las bandas de confianza.

El análisis de **residuos** ha identificado **tres valores extremos** (enero 2012, diciembre 2021 y noviembre 2023), asociados a eventos como **olas de frío, la crisis energética y ajustes en la demanda post-crisis**. Estos eventos reflejan la influencia de factores externos en la serie.